Кластеризация абонентов по интересам

Мария Платонова Екатерина Паламарчук Данил Платонов

1 Постановка задачи

Сотовый оператор накапливает данные о том, какие сайты посещают его абоненты. Эти данные сами по себе несут информацию об интересах людей: кто чаще заходит на спортивные ресурсы, кто - на образовательные, кто - на сайты ювелирных магазинов. Если научиться выделять такие группы, можно перейти от одинаковых предложений для всех к адресным кампаниям, настроенным под конкретный профиль клиента [8].

Цель работы - построить сегментацию абонентов по интересам на основе данных об интернет-активности и демографических характеристик. Результатом должны стать содержательно различимые группы, для каждой из которых можно сформулировать отдельную маркетинговую стратегию: таргетированное push-уведомление, персональную рассылку или специальный тарифный план.

Для достижения этой цели мы последовательно решали четыре задачи:

1. построить признаковое пространство на основе долей визитов по категориям сайтов;
2. сравнить несколько алгоритмов кластеризации и выбрать наилучший;
3. описать полученные сегменты с точки зрения интересов и демографии;
4. сформулировать маркетинговые рекомендации для каждого сегмента.

Примечание о данных. Все данные в исследовании *синтетические*: они сгенерированы случайным образом и не содержат реальной информации об абонентах. В реальном проекте записи о трафике дополнительно включали бы временные метки (час суток, день недели, сезонность), что позволило бы учитывать поведенческие паттерны с учётом пиковой активности. Кроме того, распределение визитов на реальных данных, как правило, подчиняется степенному закону [7]: небольшая часть активных пользователей генерирует непропорционально большую долю трафика, а возрастная структура аудитории существенно варьирует по регионам.

---

2 Данные

2.1 Описание источников

В основе анализа лежат пять таблиц (табл. 1), объединённых по ключам:

`clients.id` ↔ `activity.client_id`;

`activity.website` ↔ `websites.website`;

`websites.category_id` ↔ `categories.id`;

`clients.region_id` ↔ `regions.id`.

Файл	Строк	Содержание
`clients.csv`	50 000	Профиль клиента: идентификатор (GUID), возраст, пол (M/F), регион
`activity.csv`	1 200 000	Лог посещений: клиент и посещённый сайт
`websites.csv`	1 251	Справочник сайтов с привязкой к категории
`categories.csv`	30	30 категорий интересов (Спорт, Одежда, Путешествия и др.)
`regions.csv`	23	23 региона России

Таблица 1: Описание исходных таблиц

2.2 Качество данных и предобработка

Прежде чем переходить к моделированию, мы проверили данные на три типичных проблемы: пропуски, дубликаты и аномалии. Результаты валидации приведены в табл. 2.

Проблема	**Количество**	**Решение**
Пропущенные значения пола (`clients`)	82	Заполнены модой, исключены при анализе пола
Дубликаты пар (client_id, website) в `activity`	90 676	Оставлены как повторные визиты
Записи активности без категории сайта	8 782	Исключены при объединении таблиц
Клиенты с менее 5 визитами	7 204	Исключены для устойчивости кластеров
Итоговая выборка для кластеризации	**42 796**	

Таблица 2: Результаты валидации данных

Фильтрация клиентов с менее чем пятью визитами обоснована. Слишком короткая история активности не даёт стабильного профиля: такой клиент может случайно попасть в любой кластер. После чистки и объединения таблиц мы получили матрицу клиент × категория, где каждая строка нормирована к сумме 1 (переход к долям визитов).

3 Методология

3.1 Признаковое пространство

Для каждого клиента i мы строили вектор из 30 чисел: доля его визитов, приходящаяся на каждую из категорий сайтов:

$$x_{i,c} = \frac{v_{i,c}}{\sum_{c'=1}^{30} v_{i,c'}}, \quad c = 1, \ldots, 30,$$

где $v_{i,c}$ - число визитов клиента i на сайты категории c. Вектор $\mathbf{x}_i \in [0,1]^{30}$, $\|\mathbf{x}_i\|_1 = 1$ кодирует структуру интересов клиента независимо от того, насколько активно он пользуется интернетом в целом.

3.2 Сравнение алгоритмов кластеризации

Мы протестировали три алгоритма (табл. 3), каждый со своей логикой и ограничениями.

K-means [1] разбивает выборку на k групп, минимизируя суммарное квадратичное расстояние от точек до центроидов. Число кластеров нужно задать заранее. Это главный недостаток. Зато при инициализации по схеме K-means++ [5] алгоритм устойчив к локальным минимумам и работает быстро даже на больших данных.

Иерархическая кластеризация (Ward) [2] строит дендрограмму: на каждом шаге объединяются два ближайших кластера с минимальным приростом внутрикластерной дисперсии. Удобно, что k можно выбрать постфактум, просто «срезав» дерево на нужной высоте. Но на выборке из 40 000+ объектов вычислительные затраты ощутимо выше, чем у K-means.

DBSCAN [3] ищет кластеры как плотные области пространства: точки, у которых достаточно соседей в радиусе ε, попадают в одну группу. Число групп задавать не нужно. Проблема в другом: на наших данных при любых разумных значениях параметров (ε, $min_samples$) более 60 % клиентов оказывались в категории «шум». Такой результат непригоден для сегментации.

Метод	Задать k	Интерпретируемость	Скорость	Шум	Итог
K-means	Да	Высокая	Высокая	Нет	**Выбран**
Ward	Нет	Высокая	Низкая	Нет	Альтернатива
DBSCAN	Нет	Средняя	Средняя	$> 60\%$	Отклонён

Таблица 3: Сравнение алгоритмов кластеризации

3.3 Выбор числа кластеров

Оптимальное k мы искали двумя независимыми методами; результаты показаны на рис. 1.

Метод локтя. Для каждого $k \in \{3, \ldots, 15\}$ считали инерцию (суммарное квадратичное отклонение точек от центроидов). График инерции резко падает до $k \approx 8$, после чего выравнивается. Этот «локоть» и подсказывает разумный выбор.

Коэффициент силуэта [4] оценивает качество разбиения иначе. Для каждой точки i:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i),\, b(i)\}},$$

где $a(i)$ - среднее расстояние до объектов своего кластера, $b(i)$ - до ближайшего чужого. При $k = 8$ средний силуэт составил $\bar{s} = 0.017$. Значение невысокое, и это ожидаемо: синтетические данные генерировались без выраженных группировок, границы между сегментами изначально размыты.

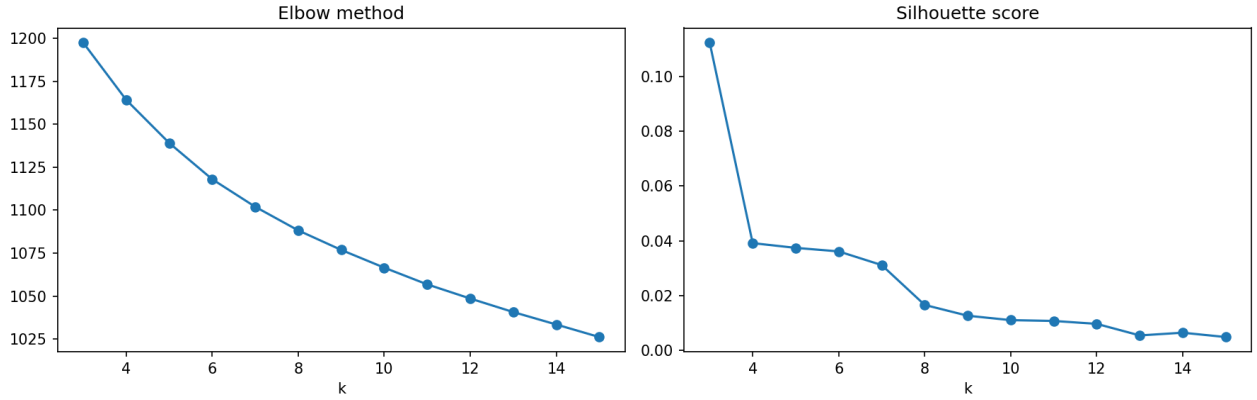

Рис. 1: Метод локтя (слева) и коэффициент силуэта (справа) для $k \in \{3, \ldots, 15\}$. Оба критерия указывают на $k = 8$.

На реальных данных. Коэффициент силуэта на реальных поведенческих данных, как правило, попадает в диапазон 0.15-0.40 [6]. Клиенты с устойчивыми предпочтениями, например те, кто смотрит только спортивный контент или читает исключительно новости, образуют плотные, чётко отделённые кластеры. Синтетическая генерация сглаживает эти различия, поэтому наш силуэт ниже, чем можно было бы ожидать.

---

4 Результаты кластеризации

4.1 Профили сегментов

K-means с $k = 8$ разбил 42 796 клиентов на восемь групп, каждая со своей доминирующей характеристикой (табл. 4). Мы дали каждому сегменту рабочее название.

#	Сегмент	Размер	Возраст	%	Топ-3 категории (доля)
0	Активный домовладелец	5 152	35.3	12.0	Стройка (0.12), Спорт (0.11), Путешествия (0.09)
1	Модный спортсмен	4 648	35.3	10.9	Аксессуары (0.14), Спорт (0.10), Ювелирные (0.08)
2	Преданный спортсмен	2 457	35.2	5.7	Спорт (0.28), Ювелирные (0.09), Каршеринг (0.06)
3	Мобильный горожанин	2 394	35.7	5.6	Каршеринг (0.15), Спорт (0.13), Ювелирные (0.08)
4	Разносторонний	12 578	35.2	29.4	Спорт (0.07), Ювелирные (0.06), Стройка (0.06)
5	Ценитель люкса	3 211	35.4	7.5	Ювелирные (0.18), Спорт (0.12), Аксессуары (0.06)
6	Активный модник	6 490	35.2	15.2	Спорт (0.15), Ювелирные (0.06), Аксессуары (0.06)
7	Образованный активист	5 866	35.4	13.7	Образование (0.09), Спорт (0.09), Ювелирные (0.07)
Итого		**42 796**	35.3	100	

Таблица 4: Профили кластеров: размер, средний возраст и топ-3 категории

Почти треть выборки приходится на кластер 4, «Разносторонний»: у этих клиентов нет выраженного фаворита среди категорий, доли распределены относительно равномерно. Полная противоположность - кластер 2, «Преданный спортсмен»: 28% всех визитов приходится на спортивные сайты, что вчетверо превышает средний показатель по всей выборке.

4.2 Тепловая карта

Тепловая карта на рис. 2 наглядно показывает, как кластеры расходятся по категориям. Кластеры 2, 3 и 6 имеют чёткие доминанты: Спорт, Каршеринг и Спорт+Аксессуары соответственно. Кластер 4, напротив, выглядит равномерно светлым, без выраженных пиков.

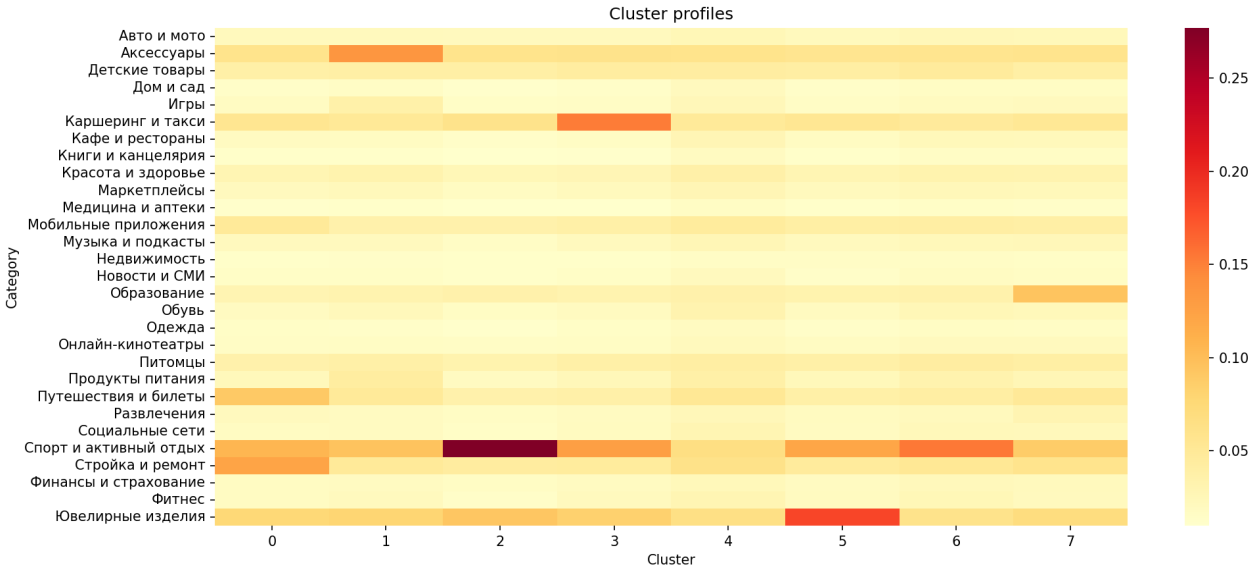

Рис. 2: Тепловая карта «кластер × категория»: средняя доля визитов. Более тёмные ячейки соответствуют более высокой концентрации интересов.

4.3 Детальные профили кластеров

На рис. 3 показаны топ-8 категорий для каждого кластера. Разброс по высоте столбцов хорошо показывает, насколько «специализированными» или «размытыми» получились отдель-

ные сегменты.

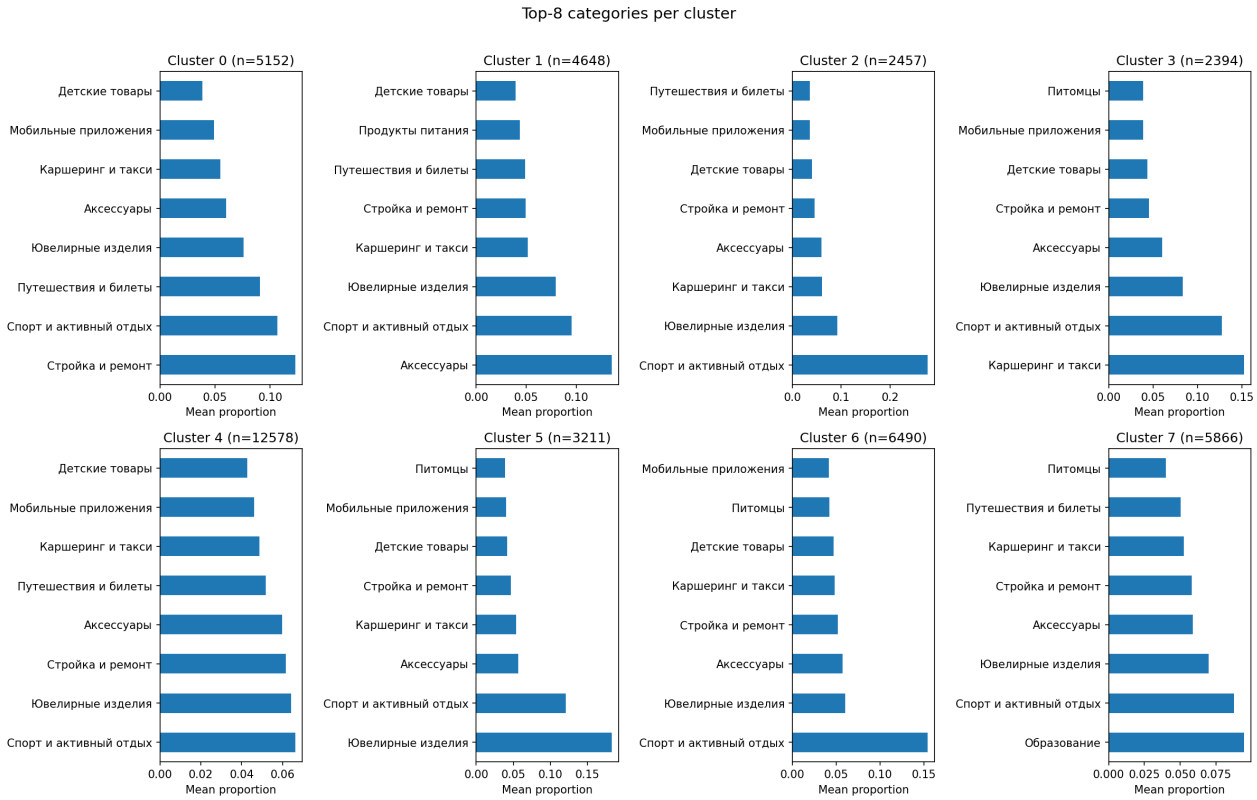

Рис. 3: Топ-8 категорий по средней доле визитов для каждого кластера.

На реальных данных. Реальный трафик следует закону Парето: порядка 20% клиентов генерируют 80% посещений. При сегментации такой аудитории профили кластеров были бы контрастнее, а коэффициент силуэта - выше. Временные метки открыли бы ещё один разрез: можно было бы выделить «ночных» пользователей, тех, кто активен преимущественно в выходные, и тех, кто серфит интернет только из офиса.

---

5 Демографический анализ

5.1 Гендерный и возрастной состав

Демографический срез восьми кластеров показан на рис. 4.

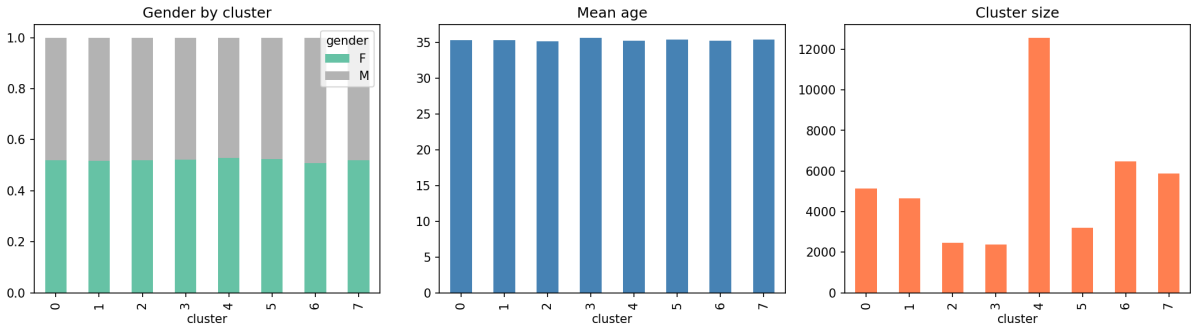

Рис. 4: Демография кластеров: гендерный состав (слева), средний возраст (в центре), размер кластера (справа).

Средний возраст колеблется в диапазоне 35.2-35.7 лет и практически не различается между кластерами. Это артефакт синтетики: возраст генерировался равномерно, без привязки к

интересам. На реальных данных картина выглядела бы иначе. Молодёжь 18-25 лет концентрировалась бы в сегментах «Одежда», «Образование» и «Игры», а пользователи 40+ заметно чаще обращались бы к категориям «Финансы», «Здоровье» и «Стройка» [8]. Гендерный состав по той же причине сбалансирован во всех кластерах примерно поровну.

5.2 Региональный состав

Топ-3 региона одинаковы для всех восьми кластеров: Саратовская область ($\approx$ 15-16%), Кемеровская область ($\approx$ 12-14%), Ленинградская область ($\approx$ 8-9%). Полная идентичность регионального профиля объясняется просто: синтетические данные не закладывали связи между регионом и интересами. На реальных данных операторов география значительно дифференцировала бы сегменты: жители Москвы и Санкт-Петербурга чаще используют каршеринг и покупают авиабилеты онлайн, а в промышленных регионах выше спрос на сайты строительной тематики и запчасти.

5.3 Маркетинговые рекомендации

Четыре кластера с наиболее выраженными профилями дают конкретные точки приложения для маркетинга.

Кластер 2 «Преданный спортсмен» (2 457 чел.) очевидно подходит для партнёрских программ с фитнес-клубами и спортивными магазинами. Push о скидках на экипировку или анонсы трансляций будут здесь максимально релевантны.

Кластер 3 «Мобильный горожанин» (2 394 чел.) активно пользуется каршерингом, значит, мобильный интернет нужен ему в дороге. Специальные тарифы на скорость и стабильность соединения, интеграция с Яндекс.Драйв или Делимобиль выглядят логично.

Кластер 5 «Ценитель люкса» (3 211 чел.) выделяется долей ювелирных сайтов: 18%, почти втрое выше среднего. Этот сегмент восприимчив к предложениям премиум-класса: VIP-тарифы, партнёрские программы с ювелирными брендами, рассылки о статусных продуктах.

Кластер 7 «Образованный активист» (5 866 чел.) - самый крупный из специализированных сегментов. Образовательные платформы (Coursera, Яндекс.Практикум), онлайн-курсы и книжные сервисы выглядят как естественные партнёры для совместных акций.

6 Выводы

K-means с $k = 8$ на векторах долей визитов по 30 категориям дал восемь читаемых, содержательно различимых сегментов. Из трёх протестированных алгоритмов именно K-means обеспечил лучшее сочетание скорости, интерпретируемости и пригодности для маркетинговых задач. Ward мог бы стать альтернативой, DBSCAN отсеялся из-за высокого уровня шума.

Сегменты действительно разные. Разброс доминирующих категорий: от 28% визитов на спортивные сайты у «Преданного спортсмена» до 18% на ювелирные у «Ценителя люкса» и 15% на каршеринг у «Мобильного горожанина». Этого достаточно, чтобы строить под каждый сегмент отдельную коммуникационную стратегию.

Демографические различия между кластерами минимальны, и это не результат анализа. Возраст и пол в синтетических данных генерировались независимо от интересов. На реальных данных оба признака стали бы дополнительными разделителями и только усилили бы практическую ценность сегментации.

Ограничения. Низкий средний силуэт ($\bar{s} = 0.017$) объясняется синтетической природой данных, а не методологической ошибкой. Отсутствие временных меток закрывает целый класс поведенческих признаков: время суток, частоту сессий, длительность визитов. В реальном проекте их стоит включить в признаковое пространство в первую очередь.

Список литературы

[1] MacQueen J. B. Some Methods for Classification and Analysis of Multivariate Observations // Proc. of the 5th Berkeley Symposium on Mathematical Statistics and Probability. — 1967. — Vol. 1. — P. 281–297.

[2] Ward J. H. Hierarchical Grouping to Optimize an Objective Function // Journal of the American Statistical Association. — 1963. — Vol. 58, No. 301. — P. 236–244.

[3] Ester M., Kriegel H.-P., Sander J., Xu X. A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise // Proc. of the 2nd Int. Conference on Knowledge Discovery and Data Mining (KDD-96). — Portland, 1996. — P. 226–231.

[4] Rousseeuw P. J. Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis // Journal of Computational and Applied Mathematics. — 1987. — Vol. 20. — P. 53–65.

[5] Arthur D., Vassilvitskii S. K-means++: The Advantages of Careful Seeding // Proc. of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA). — 2007. — P. 1027–1035.

[6] Sculley D. Web-Scale K-Means Clustering // Proc. of the 19th Int. Conference on World Wide Web (WWW). — 2010. — P. 1177–1178.

[7] Clauset A., Shalizi C. R., Newman M. E. J. Power-Law Distributions in Empirical Data // SIAM Review. — 2009. — Vol. 51, No. 4. — P. 661–703.

[8] Котлер Ф., Армстронг Г. Основы маркетинга / пер. с англ. — 14-е изд. — М.: Вильямс, 2017. — 752 с.